

# 拡張 Lagrange 法

中村 祐介

(2015 年 10 月 19 日)

## 1 制約条件なし 極小化問題

以下の様な極小化問題を考える。

$E[f]$  を極小化する  $f$  を求める。  
ただし  $f = (f_0, f_1, \dots, f_{M-1})$ 。

極小値を与える  $f$  を  $f^o$  とすると、以下の式が成立していることが必要である：

$$\frac{\partial E[f^o]}{\partial f_m} = 0 \quad (1)$$

これを「1 次の必要条件」という。1 次の必要条件を満たすだけでは、極小とは限らない。しかし以下の条件が成立する場合、極小であると十分いえる：

$$\frac{\partial^2 E[f^o]}{\partial f_m \partial f_n} \text{ が正定値} \quad (2)$$

これを「2 次の十分条件」という。

極小値問題は数値計算では「降下法」を用いると効率的に解ける。降下法ではある適当な点  $f^1$  を仮定して、山を下る要領で  $E[f^1] > E[f^2] > E[f^3] > \dots$  を満たす  $f^i$  を次々に求めていく方法である。その中でも一番な「最急降下法」について述べる。最急降下法では現在地点を  $f^i$  として、 $E[f^i] > E[f^{i+1}]$  となる  $f^{i+1}$  を

$$f^{i+1} = f^i - \alpha \frac{\partial E[f^i]}{\partial f} \quad (3)$$

と選ぶ。ただし  $\alpha$  は十分に小さい正の数である。つまり現在地点の勾配を見て、最も下る方向（いわゆる最急降下方向）にステップ幅  $\alpha$  で移動する。 $\alpha$  が十分小さければ、 $E[f^{i+1}] < E[f^i]$  が保証されるので、近くに極小値があればそこに収束するはずである。つまり  $f^o$  において 2 次の十分条件が満たされているのならば、その近傍で最急降下法は収束性を持っている。

### 1.1 $\alpha$ の決め方

$\alpha$  が十分に小さければ収束性が良くなるが、小さい  $\alpha$  では収束までにたくさんのステップ数が必要となる。計算の高速化のためには、収束を保証しつつも、出来るだけ  $\alpha$  の値を大きく選んだ

い。この観点では  $\alpha$  は  $E[f^{i+1}]$  が出来るだけ小さくなるように、選ぶのが良い。つまり

$$\frac{\partial}{\partial \alpha} E \left[ f^i - \alpha \frac{\partial E[f^i]}{\partial f} \right] = 0 \quad (4)$$

と選ぶ。この選び方を  $\alpha$  についての「正確な直線探索」という。上式は合成関数の微分より

$$\sum_m \frac{\partial E[f_i]}{\partial f_m} \frac{\partial E[f_i - \frac{\partial E[f^i]}{\partial f}]}{\partial f_m} = 0 \quad (5)$$

と書くことも出来る。つまり、 $f^{i+1}$  における勾配と  $f^i$  における勾配が直交するような  $\alpha$  を選ぶことになる。これが最適であることが直感的にもすぐ分かる。

実際には正確な直線探索は計算コストが膨大なので、ある程度手を抜いて求めるのが良い。

## 2 制約条件付き極小化問題

解きたい問題以下の通り

制約条件  $G_r[f] = 0$  の下で、 $E[f]$  を極小化する  $f$  を求める。  
 ただし  $f = (f_0, f_1, \dots, f_{M-1})$ ,  $r = 0, 1, \dots, R-1$ 。

この時の 1 次の必要条件は

$$\exists v_r^o \quad \text{s.t.} \quad \frac{\partial E[f^o]}{\partial f_m} + \sum_r v_r^o \frac{\partial G_r[f^o]}{\partial f_m} = 0, \quad (6)$$

$$G_r[f^o] = 0 \quad (7)$$

である。

### 2.1 Lagrange 未定乗数法

$f, v$  を独立変数に持つ以下の関数を考える：

$$E'[f, v] = E[f] + \sum_r v_r G_r[f] \quad (8)$$

すると 1 次の必要条件 (6) は

$$\frac{\partial E'[f^o, v^o]}{\partial f_m} = 0, \quad \frac{\partial E'[f^o, v^o]}{\partial v_r} = 0 \quad (9)$$

と書き換えることが出来る。これは  $(M + R)$  次元の制約条件なし極小化問題の 1 次の必要条件と同じ構造をしている。このようにして次元を上げる代わりに、制約条件を無くす方法を Lagrange 未定乗数法という。 $v$  は Lagrange 未定乗数と呼ばれる。

注意しなくてはいけないのは、 $E'$  は 2 次の十分条件を満たさないということである。「満たすとは限らない」ではなく、 $G \equiv 0$  の様な自明な例を除けば「必ず満たさない」のである。つまり  $E$  の制約条件付きの極小点  $(f^o, v^o)$  は  $E'$  の極小点になることはなく、必ず鞍点になる。 $(f^o, v^o)$  は 2 次の十分条件を満たさないので、最急降下法は収束しない。

降下法は使えないが、例えば  $M + R$  元の非線形連立方程式 (6) を解くことで、停留点  $(f^o, v^o)$  を見つけることも出来る。しかしそれは一般には非常に難しい問題である。

## 2.2 拡張 Lagrange 法

拡張 Lagrange 法では Lagrange 未定乗数を導入しつつも、問題が停留値問題ではなく、極小値問題になるように工夫している。具体的には Lagrange 関数と呼ばれる以下の関数を考える：

$$L[f, v] = E[f] + \sum_r \left( v_r G_r[f] + \frac{\rho}{2} G_r^2[f] \right) \quad (10)$$

ここで  $\rho$  は手で与える十分に大きいパラメータである。

### 2.2.1 Lagrange 関数に対する極小値問題

本来未知の  $v^o$  を既に知っているとし、 $L[f, v^o]$  を  $f$  のみの関数だとして、制約なし極小値問題を考えよう。この時の 1 次の必要条件は

$$\frac{\partial L[\bar{f}, v^o]}{\partial f_m} = \frac{\partial E[\bar{f}]}{\partial f_m} + \sum_r \left( v_r^o + \rho G_r[\bar{f}] \right) \frac{\partial G_r[\bar{f}]}{\partial f_m} = 0 \quad (11)$$

となる。ここで  $\bar{f}$  は  $L[f, v^o]$  の停留点である。もともとの 1 次の必要条件 (6), (7) を満たす  $(f^o, v^o)$  ならば、 $L$  の 1 次の必要条件を見たすことが分かる。逆に  $G_r[\bar{f}] = 0$  を満たすのならば、 $\bar{f} = f^o$  であることもすぐ分かる。

つづいて  $L$  の 2 次の十分条件を調べると

$$\frac{\partial^2 L[\bar{f}, v^o]}{\partial f_m \partial f_n} = \frac{\partial^2 E[\bar{f}, v^o]}{\partial f_m \partial f_n} + \sum_r \left( v_r^o + \rho G_r[\bar{f}] \right) \frac{\partial^2 G_r[\bar{f}]}{\partial f_m \partial f_n} + \rho \sum_r \frac{\partial G_r[\bar{f}]}{\partial f_m} \frac{\partial G_r[\bar{f}]}{\partial f_n} \quad (12)$$

となっている。特に  $\bar{f} = f^o$  の場合を考えると

$$\frac{\partial^2 L[f^o, v^o]}{\partial f_m \partial f_n} = \frac{\partial^2 E[f^o, v^o]}{\partial f_m \partial f_n} + \sum_r \left( v_r^o \frac{\partial^2 G_r[f^o]}{\partial f_m \partial f_n} + \rho \frac{\partial G_r[f^o]}{\partial f_m} \frac{\partial G_r[f^o]}{\partial f_n} \right) \quad (13)$$

となっている。ここで  $\frac{\partial G_r[\bar{f}]}{\partial f_m} \frac{\partial G_r[\bar{f}]}{\partial f_n}$  が半正定値行列であることに注目する。もし  $\rho$  が十分に大きければ、この項が支配的になるので、何となく  $\frac{\partial^2 L[f^o, v^o]}{\partial f_m \partial f_n}$  が正定値行列っぽくなる<sup>\*1</sup>。すると 2 次の十分条件を満たすので、降下法が使えるようになる。また停留点  $\bar{f}$  は極小点となる。

<sup>\*1</sup> もっと数学的にぎりぎりを攻めれば、証明できるらしい。

まとめると以下の通り。 $\rho$  が十分大きくかつ  $v^o$  が既知であれば、 $L[f, v^o]$  の  $f$  についての条件なし極小値問題が降下法で解ける。さらにこの時の極小点  $\bar{f}$  が  $G_r[\bar{f}] = 0$  を満たすのであれば、それが求めたかった  $f^o$  である。

### 2.2.2 $v^o$ の求め方

実際は  $v^o$  が既知であることはありえない。つまり  $v^o$  を求める手順が必要である。そこである適当な  $v$  を選んで  $L[f, v]$  を  $f$  について極小化してみる。1 次の必要条件は

$$\frac{\partial L[\bar{f}, v]}{\partial f_m} = \frac{\partial E[\bar{f}, v]}{\partial f_m} + \sum_r \left( v_r + \rho G_r[\bar{f}] \right) \frac{\partial G_r[\bar{f}]}{\partial f_m} = 0 \quad (14)$$

である。ここでもし  $G_r[\bar{f}] = 0$  ならば

$$\frac{\partial E[\bar{f}, v]}{\partial f_m} + \sum_r v_r \frac{\partial G_r[\bar{f}]}{\partial f_m} = 0 \quad (15)$$

となる。これはもともとの 1 次の必要条件 (6) そのものであるので、問題はすでに解けており、 $v = v^o$ ,  $\bar{f} = f^o$  であったことになる。逆に  $G_r[\bar{f}] \neq 0$  となってしまったのならば、それは  $v \neq v^o$  であったためである。その場合は、 $v$  を選び直さなくてはならない。式 (14) と式 (15) を見比べると

$$v_r + \rho G_r[\bar{f}] \longrightarrow v_r \quad (16)$$

と取り直すのが、良さそうだと予想できる\*2。

まとめると以下の通り。ある  $v$  を与えて  $L[f, v]$  の  $f$  に関する制約条件なし極小値問題を解く。その後、式 (16) で  $v$  を定義し直すと、 $v$  は前よりも  $v^o$  に近づいている。

## 3 拡張 Lagrange 法のアルゴリズム

### 3.1 プロトタイプ

以下に示すのが拡張 Lagrange 法のアルゴリズムである。

1.  $v^o$  に対する推定値  $v^1$  を与える。 $k = 1$  とする。
2.  $v^k$  を固定して  $L[f, v^k]$  の制約条件なし極小値問題を解き、極小値を与える  $f$  を  $f^k$  とする。
3. もし  $G[f^k, v^k] = 0$  ならば、 $(f^o, v^o) = (f^k, v^k)$  であるので、計算を終了する。
4. 一方  $G[f^k, v^k] \neq 0$  ならば、それは  $v^k \neq v^o$  であったためである。そこで  $v$  以下の公式で修正する：

$$v^{k+1} = v^k + \rho G[f^k] \quad (17)$$

---

\*2 実際に良いことが証明できるが、難しいので略。

5.  $k = k + 1$ として、2.に戻る。

手順 2. で条件なしの極小値問題を解かなくてはならないが、その手法は任意である。

### 3.2 改良版その1

ここから先は、中村が考えたアルゴリズムである。まだ改善途中なので、ほかのアイデアも試して欲しい。

プロトタイプアルゴリズムは数学的に見通しが良いが、数値計算上では無駄が多い。手順 2. で正確に極小値問題を解かず、途中で打ち切ってしまうのが良い。中でも最急降下法で 1 ステップだけ下るのが効率が良い。

一般により 高級な降下法(例えばニュートン法など)で下るほうが 1 ステップで大きく下れるが、そもそも  $v^k$  が  $v^o$  に近い保証はないので、大きく下るのは危険である。小さなステップを数多く重ねるのなら、計算量の観点から最急降下法が優れているのである。

従ってアルゴリズムは以下の様になる：

1.  $v^o, f^o$  に対する推定値  $v^1, f^1$  を与える。 $k = 1$  とする。
2.  $v^k$  を固定して  $L[f, v^k]$  に対して  $f$  の最急降下法で 1 ステップ下る。具体的には  $f^{k+1} = f^k - \alpha \frac{\partial L}{\partial f}$  とする。ここで  $\alpha$  は適切なステップ幅。
3. もし  $G[f^k, v^k] = 0$  かつ  $\frac{\partial L}{\partial f} = 0$  ならば、 $(f^o, v^o) = (f^k, v^k)$  として計算を終了する。
4. そうでなければ以下の公式で  $v$  を修正する：

$$v^{k+1} = v^k + \rho G[f^k] \quad (18)$$

5.  $k = k + 1$ として、2.に戻る。

つまり  $f$  の降下と  $v$  の修正を交互にしていく。手順 2. の  $\alpha$  は大きすぎると破綻するが、小さすぎると計算が遅い。毎回  $\alpha$  を直線探索(もしくは Armijo の方法、Wolfe の方法など)で決める方が、収束までのループ回数が減る。しかし、逆に直線探索に時間が掛かるので、1 ループあたりに掛かる時間が増える。

### 3.3 改良版その2

計算が速くなるように、できるだけ大きな  $\alpha$  を使いたいが、 $\alpha$  の直線探索で決めようとする、それに時間が掛かる。そこでループごとに少しずつ改善する方法を採用しよう。つまり最初はある程度小さな  $\alpha_{\text{ini}}$  で計算を始めて、 $L$  の変化を見ながら次のループの  $\alpha$  を決定していく。以下の方法で上手くいった：

- もし  $L[f^{k+1}, v^{k+1}] > L[f^k, v^k]$  ならば  $\alpha \leftarrow \max[\alpha_{\text{ini}}, \alpha \gamma_1]$ 。

- もし  $L[f^{k+1}, v^{k+1}] < L[f^k, v^k]$  ならば  $\alpha \leftarrow \alpha\gamma_2$ 。

つまり  $L$  の極小化が上手く働いたら次のループでは  $\alpha$  は大胆にとり、失敗したら控え目にする。ここで  $\alpha_{\text{ini}} = 0.01, \gamma_1 = 0.5, \gamma_2 = 1.1$  くらいが丁度良い。このアルゴリズムをさらに数値計算向けに書き換えたものを「ALSolver3 の使い方」に載せてある。

## 4 さらに改良版

ここまでの拡張 Lagrange 法に以下の 2 つの改良を加える。

### 4.1 制約条件の改良

例えば、 $G_1 \equiv 1 - \sum \dots = 0$ ,  $G_2 \equiv N - \sum \dots = 0$  の様な規格化と粒子数に関する制約条件を課すことがある。しかし  $N$  が大きい場合、両者の強さに違いがありすぎるので、計算がかなり不安定になってしまう。これは  $G_r = 0$  という制約条件では  $G \rightarrow cG$  の様なスケール変換を許してしまっていることに起因する。最適な  $\rho$  の選び方がほぼ不可能になっている。(「 $G_1$  に対しては大きすぎ、 $G_2$  に対しては小さすぎる」というジレンマに陥る可能性がある?)

つまり、制約条件の強さを揃える形式すべきである。そこで制約条件は

$$G_r \equiv 1 - C_r = 0 \quad (19)$$

という形に制限することにする。これで、 $r$  毎の制約条件の強さのばらつきが抑えられるはずである。先ほどの例で云うならば、

$$G_2 = 1 - \frac{1}{N} \sum \dots \quad (20)$$

のように予め  $N$  で割っておくことを強制する。

### 4.2 条件数の改善

$L$  の  $f$  に関する最急降下法を使うわけだが、最急降下法は  $L$  の条件数 (Hesse 行列の最大固有値と最小固有値の比) が大きいと極端に収束性が悪くなってしまう。そこで、出来るだけ低コストで条件数を下げたい。

ここで行うような条件数を下げる処理を「前処理」という。今回はその中でも最も単純で低コスト (で当然低性能) な Jacobi 前処理を応用した前処理を施すことにする。

#### 4.2.1 Jacobi 前処理

以下の様に正定値行列  $A$  を使って定義される  $L[x]$  の最小値問題を考える：

$$L = x^\dagger A x \quad (21)$$

さて、ある正則行列  $P$  を用いて

$$L = \mathbf{y}^\dagger B \mathbf{y}, \quad \mathbf{y} = P^{-1} \mathbf{x}, \quad B = P^\dagger A P \quad (22)$$

と書き換えても数学的に当然等価である。そして、 $B$  の条件数を  $A$  の条件数よりも小さくするような  $P$  を得ることが出来たとする。すると  $B$  に対して最急降下法を適用すれば、 $A$  に対して適用するより、速く収束してくれる。極端な例として、 $P = A^{-1/2}$  と選ぶと、 $B$  は単位行列となるので、最急降下法は任意の初期推定値に対して、反復回数 1 で真の解に収束する。とはいえ  $A^{-1/2}$  の計算は  $L$  の最小化というもとの問題よりもはるかに難しいので、実用的ではない。重要なのは、いかに少ない計算量で  $A^{-1/2}$  に近い行列を見つけてくるかということである。

Jacobi 前処理では  $P$  を

$$P_{nm} = \delta_{nm} \frac{1}{\sqrt{A_{nn}}} \quad (23)$$

と選ぶ。 $A$  の対角優位性が強い場合、この選び方は  $A^{-1/2}$  の良い近似になっている。

#### 4.2.2 Jacobi 前処理を適用する

もともとの Lagrange 関数は

$$L[f, v] = E[f] + \sum_r \left( v_r G_r[f] + \frac{\rho}{2} G_r^2[f] \right) \quad (24)$$

である。ここで

$$g_m = \sqrt{p_m} f_m \quad (25)$$

という変数変換をする。 $p_m$  の具体形は後で考える。 $L$  を  $g$  の関数だと思って、最急降下法を適用しよう。 $L$  の  $g$  に関する Hesse 行列は

$$\frac{\partial^2 L}{\partial g_m \partial g_n} = \frac{\partial^2 E}{\partial g_m \partial g_n} + \sum_r \left[ (v_r + \rho G_r) \frac{\partial^2 G}{\partial g_m \partial g_n} + \rho \frac{\partial G_r}{\partial g_m} \frac{\partial G_r}{\partial g_n} \right] \quad (26)$$

$$= \frac{1}{\sqrt{p_m p_n}} \left\{ \frac{\partial^2 E}{\partial f_m \partial f_n} + \sum_r \left[ (v_r + \rho G_r) \frac{\partial^2 G}{\partial f_m \partial f_n} + \rho \frac{\partial G_r}{\partial f_m} \frac{\partial G_r}{\partial f_n} \right] \right\} \quad (27)$$

Jacobi 前処理の精神に則れば

$$p_m = \frac{\partial^2 E}{\partial f_m \partial f_m} + \sum_r \left[ (v_r + \rho G_r) \frac{\partial^2 G}{\partial f_m \partial f_m} + \rho \left( \frac{\partial G_r}{\partial f_m} \right)^2 \right] \quad (28)$$

と選ぶのが良さそうである。しかし式 (25) から分かる通り、 $p_m > 0$  でないといけない。数学的には  $p_m$  が非常に小さな正数でも OK であるが、数値計算上は危険なので、ある適当な  $p_{\min}$  を設定して、

$$p = \max \left\{ \frac{\partial^2 E}{\partial f_m \partial f_m} + \sum_r \left[ (v_r + \rho G_r) \frac{\partial^2 G}{\partial f_m \partial f_m} + \rho \left( \frac{\partial G_r}{\partial f_m} \right)^2 \right], p_{\min} \right\} \quad (29)$$

と選ぶことにする。

最急降下法の 1 ステップは

$$g_m^{k+1} = g_m^k - \alpha \frac{\partial L}{\partial g_m} \quad (30)$$

である。式 (25) を用いて、 $f$  の言葉に戻すと

$$f_m^{k+1} = f_m^k - \frac{\alpha}{p_m} \frac{\partial L}{\partial f_m} \quad (31)$$

となる。手順 2 の降下法の部分を上式に置き換えればよい。

以上2 つの改良を施したソルバーの使い方を「ALSolver4 の使い方」に載せてある。